この資料のゴール

「+2.1」が出るまで 集計・重み付け・分析名を順に理解する

合成データCの地域間分析を例に、個人のデータがどのように県別の集計へ変わり、1つの傾きになるのかを追います。

県の平均血糖値が10高いときの、
直線上の発症割合の差

+2.1 ポイント

この順番で読むと、計算の意味がつながります。

1	2	3	4	5	6
県別に集計	県を点にする	人数を重みに	傾きを読む	名前を知る	B・Cを比較

今回使うデータ

記号	データ	比較対象
B	元データ	共通34都道府県の967人
C	合成データ	共通34都道府県の1,049人

主な説明はCの実際の集計です。ここでの「県の平均」は、今回のデータに含まれるその県の人たちから計算しています。

STEP 1 · 個人のデータから県別の値へ

県ごとに、平均と割合を求める

使う項目は「都道府県」「血糖値（FPG）」「発症の有無」です。発症した人を1、していない人を0として、県ごとにまとめます。

合成データCの実際の集計から、3都県を抜粋

都県	人数	平均血糖値	発症した人数	発症割合
東京都	384人	91.62	33人	8.59%
神奈川県	53人	90.47	2人	3.77%
千葉県	37人	96.33	4人	10.81%

東京都を、1つずつ計算すると

平均血糖値 ＝ 血糖値の合計 ÷ 人数

35,182.56 ÷ 384 ≒ **91.62**

発症割合 ＝ 発症した人数 ÷ 人数 × 100

33 ÷ 384 × 100 ≒ **8.59%**

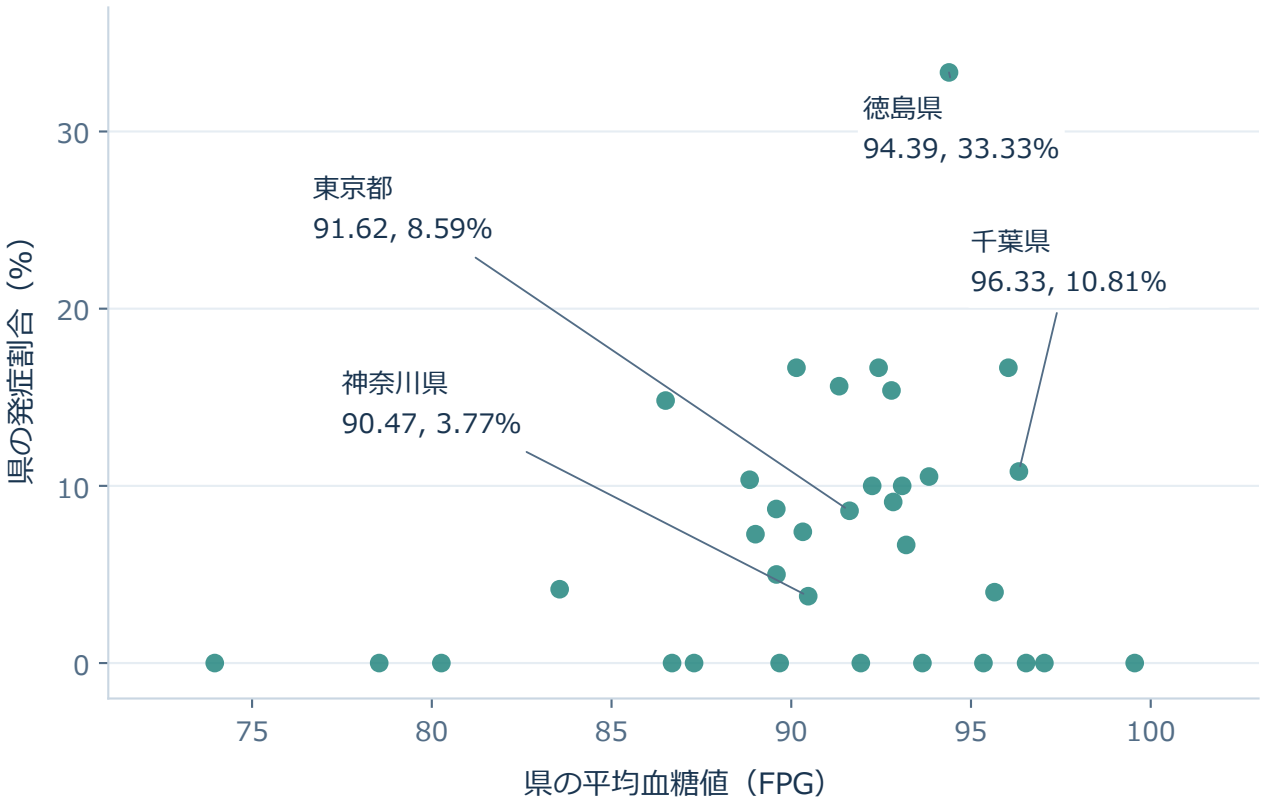
発症割合は、観察期間中に発症した人が集団の中で占める割合です。今回の観察終了は約10年です。

表示値は丸めています。計算には丸める前の値を使います。BとCに共通する34都道府県について、同じ集計を行います。

STEP 2・県を点にする

1つの県を、1つの点で表す

横軸は県の平均血糖値、縦軸は県の発症割合です。東京都なら「91.62、8.59%」の位置に点を置きます。



合成データCの共通34都道府県。点はすべて実際の集計値で、説明のため4都県に名前を付けています。

34県をまとめた傾向を見たい

点は一直線には並びません。そこで、点全体に1本の直線を当てはめ、「平均血糖値が高い県ほど、発症割合も高いか」を傾きで要約します。

STEP 3・人数で重み付けする

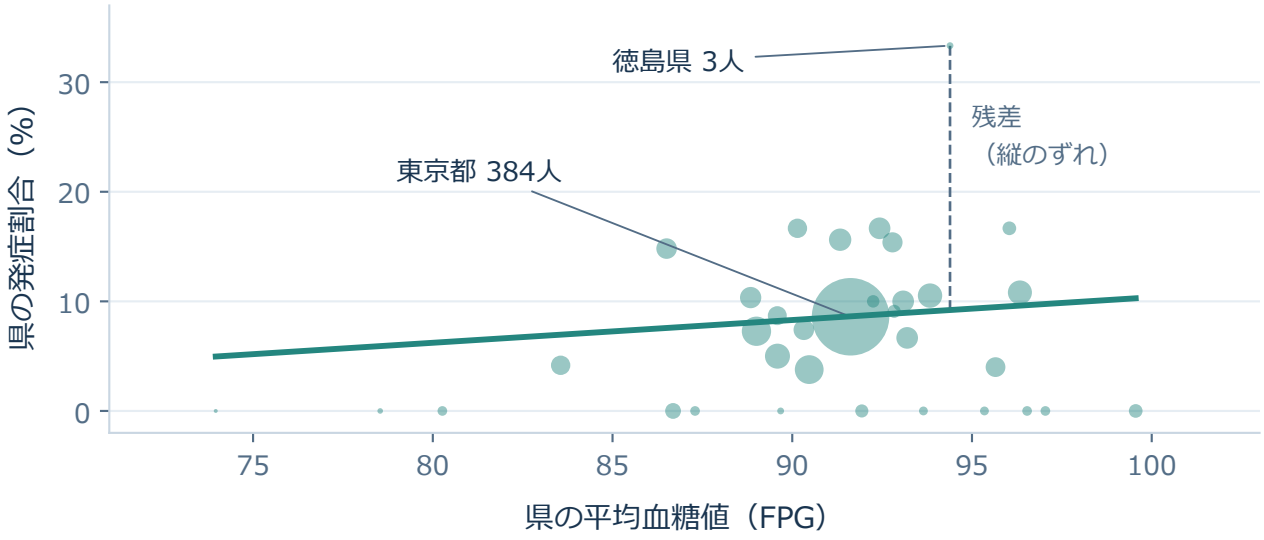
人数の違いを反映して、直線を求める

各県の点と回帰直線の縦のずれを「残差」と呼びます。残差を二乗して、その県のデータ人数を掛けます。34県分の合計が最小になる直線を選びます。[1]

仮に、どちらの県も残差が＋2ポイントなら

県	データ人数	人数 × 残差²
東京都	384人	384 × 2² = 1,536
徳島県	3人	3 × 2² = 12

＋2も−2も、二乗すると4になります。同じ残差なら、東京都の寄与は徳島県の128倍です。直線への実際の影響は、点の位置にも依存します。



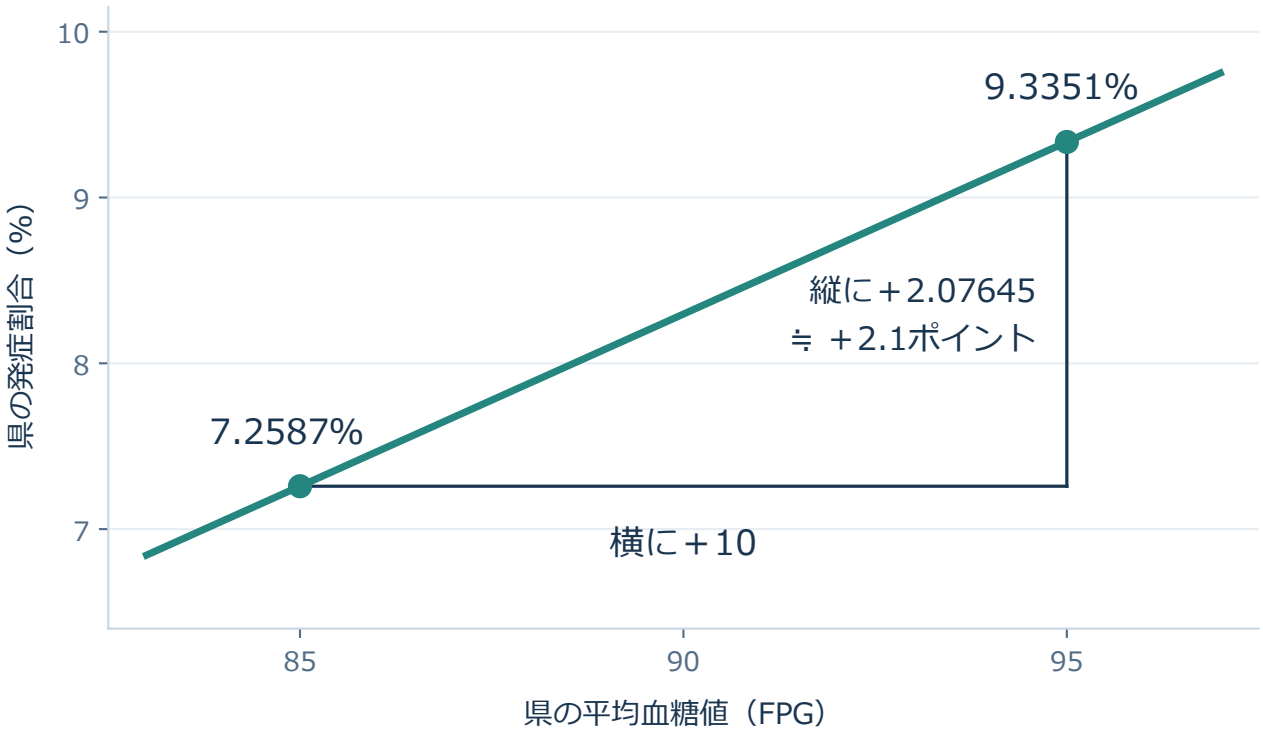
点の面積は県のデータ人数。破線は、同じ平均血糖値での点と直線の縦のずれ（残差）です。表の「＋2ポイント」は、説明用の仮定です。

目的は、県別人数の違いを反映した県間の傾向を求めることです。使う重みはデータ内の人数であり、各県の住民総数ではありません。

STEP 4・傾きを読む

直線上の差が「＋2.1」になる

求めた直線の一部を拡大します。平均血糖値85と95の位置で、直線の高さを比べます。どちらも今回の県平均の範囲内です。



横の差：95 − 85 = 10

縦の差：9.3351% − 7.2587%

≒ 2.07645ポイント ≒ **＋2.1ポイント**

「傾き」との関係

血糖値1あたりの傾きは約0.2076ポイントです。
これを10倍して丸めた「＋2.1」は、血糖値10あたりの傾きです。

直線上の値は表示を丸めています。差の計算には丸める前の値を使っています。

STEP 5・分析の名前

同じ分析を、3つの観点から呼ぶ

何を計算するか、何を単位にするか、どの関係を分けるかで、呼び方が変わります。

計算方法の名前

人数で重み付けした単回帰分析

血糖値という1つの説明変数から、発症割合との直線的な関係を求めます。各県の人数を重みにした加重最小二乗法（WLS）を使っています。[1]

分析する単位に着目した名前

生態学的分析（ecological analysis）

県などの集団を単位にして、集団の平均値どうしの関係を調べる分析です。今回の「地域間」の部分が該当します。[2]

今回の比較全体を説明する名前

県内・県間に分けた記述的分析

within-between分析と説明できます。県内の個人間の関係と、県平均どうしの関係を分けて調べます。ここでのwithinは、同じ県に属する人々の違いを指します。[3]

発表での言い方：個人レベルと地域レベルの関連を比較する回帰分析。

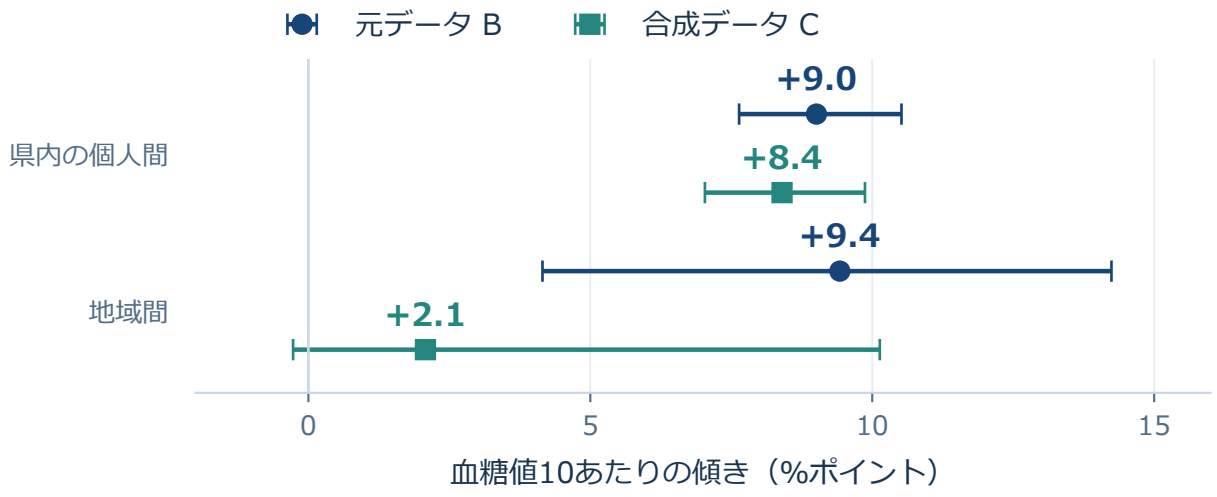
STEP 6 · 元データと合成データを比べる

Bで得られた関係は、Cでも見られるか

BとCに同じ方法を適用し、FPGが10高いときの傾きを比較します。県内と地域間で、関係の保たれ方が同じかを確認します。

県内の個人間：血糖値と発症の有無から、それぞれの県平均を引き、同じ県の人どうしの関係を求めます。

地域間：県の平均血糖値と発症割合から、人数で重み付けした傾きを求めます。



点：元の表から求めた傾き。横線：県ごとの人数を保ち、各県内で人を重複ありで選び直す計算を2,000回行ったときの、傾きの中央95%範囲。長いほど、選び直しによる揺れが大きいことを示します。BとCの差の検定をしているわけでない。

今回の値から読み取れること

県内の個人間では、Bの＋9.0とCの＋8.4は近い値でした。地域間では、Bの＋9.4に対しCは＋2.1でした。

→ 匿名化によって変わってしまった部分の可能性

評価しているのは、今回のB・Cという2つの表における関連の保たれ方です。年齢などの他の項目は、同時には調整していません。

補足・後から確かめるために

再計算の要点と、読み取りの範囲

Cの地域間の直線を、数値で確かめる

人数で重み付けした平均は、FPGが91.36137、発症割合が8.57960%です。各県の「平均との差」から傾きを計算します。

傾き ＝ 1,707.54610 ÷ 8,223.38900 ≒ 0.20764506

直線：発症割合（%）＝ −10.3911384 ＋ 0.20764506 × FPG

分子は「人数 × FPGの平均との差 × 発症割合の平均との差」の合計。分母は「人数 × FPGの平均との差の二乗」の合計です。

補足しておきたい3点

① **対象の範囲：**BとCに共通する34都道府県を比較。Cにない13県のBの82人は除外しています。発症前に死亡した人は、この発症割合では非発症として数えています。

② **重みの選び方：**主結果はB・Cそれぞれの県別人数を使用。CをBの人数配分にそろえると、地域間の傾きは＋1.3でした。主図の＋2.1はC自身の人数を使った値です。

③ **生態学的誤謬との関係：**地域の関係を個人にそのまま当てはめると、誤った推論につながり得ます。今回は、県内と県間を分けて確認しています。[2]

計算資料と参考文献

解析資料：2026-10-14出力の run_analysis.py、prefecture_aggregates.csv、all_slopes.csv、common_B_weight_sensitivity.csv。係数は県別集計から独立に再計算し、一致を確認しました。

[1] NIST/SEMATECH. Weighted Least Squares.

[2] NCBI Bookshelf. Environmental-Epidemiology Studies: Their Design and Conduct.

[3] StataCorp. What is the between estimator?

[3]は集団内・集団間を分ける考え方の参考。今回の集団は都道府県です。